LAB08_Shiguihara

Gabriel Furlan Shiguihara

Importando Polars

```
import polars as pl
print("Versao do Polars:", pl.__version__)
```

```
Versao do Polars: 1.33.1
```

```
null_values = ["\\N"]

pl.Config.set_tbl_rows(20)
```

```
<class 'polars.config.Config'>
```

```
pl.Config.set_tbl_cols(20)
```

```
<class 'polars.config.Config'>
```

```
pl.Config.set_fmt_str_lengths(60)
```

```
<class 'polars.config.Config'>
```

Leitura dos dados

Os arquivos `.tsv.gz` devem estar na mesma pasta deste `.qmd`.

1.1 Criando a `basics`

```
schema_basics = {
    "tconst": pl.String,
    "titleType": pl.String,
    "primaryTitle": pl.String,
    "originalTitle": pl.String,
    "isAdult": pl.Int64,
    "startYear": pl.Int64,
    "endYear": pl.Int64,
    "runtimeMinutes": pl.Int64,
    "genres": pl.String,
}

basics = pl.read_csv(
    "title.basics0.tsv.gz",
    separator="\t",
    null_values=null_values,
    quote_char=None,
    schema_overrides=schema_basics,
)
```

1.2 Criando a `ratings`

```
schema_ratings = {
    "tconst": pl.String,
    "averageRating": pl.Float64,
    "numVotes": pl.Int64,
}

ratings = pl.read_csv(
    "title.ratings.tsv.gz",
    separator="\t",
    null_values=null_values,
    quote_char=None,
    schema_overrides=schema_ratings,
)
```

1.3 Criando a `principals`

```
schema_principals = {
    "tconst": pl.String,
    "ordering": pl.Int64,
    "nconst": pl.String,
    "category": pl.String,
    "job": pl.String,
    "characters": pl.String,
}

principals = pl.read_csv(
    "title.principals0.tsv.gz",
    separator="\t",
    null_values=null_values,
    quote_char=None,
)
```

Base de filmes avaliados

Junção de `basics` com `ratings`, mantendo apenas títulos do tipo `movie`.

```
filmes = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
)
print(filmes.shape)
```

```
(316981, 11)
```

Atividade

Questão 1: 5 filmes com as maiores notas (desempate por número de votos)

```
q1 = (filmes.sort(["averageRating", "numVotes"], descending=[True, True])
    .select(["tconst", "primaryTitle", "averageRating", "numVotes"])
    .head(5)
)
print(q1)
```

```
shape: (5, 4)

 tconst      primaryTitle               averageRating  numVotes
 ---         ---                        ---            ---
 str         str                        f64            i64

 tt33075815  Kaveri                     10.0           1023
 tt27815015  Kurukku                    10.0           451
 tt28450376  Jedal Dar Omghe 30 Metri   10.0           142
 tt27859713  Sargashte                  10.0           134
 tt33507675  Gorgeous Rascal            10.0           115
```

Questão 2: gênero mais frequente entre os filmes com nota maior que 8

```
q2 = (
    filmes
    .filter(pl.col("averageRating") > 8)
    .with_columns(pl.col("genres").str.split(",").alias("genero"))
    .explode("genero")
    .group_by("genero")
    .agg(pl.len().alias("n_filmes"))
    .sort(["n_filmes", "genero"], descending=[True, False])
    .head(10)
)
print(q2)
```

```
shape: (10, 2)

 genero      n_filmes
 ---         ---
 str         u32
```

```
Documentary   10564
Drama         8114
Comedy        3186
Biography     1395
Romance       1363
Action        1355
Music         1248
Thriller      1184
History       1030
Crime         977
```

```
print("Gênero mais frequente:", q2["genero"][0], "-", q2["n_filmes"][0], "filmes")
```

```
Gênero mais frequente: Documentary - 10564 filmes
```

Questão 3: 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5

```
filmes_75 = filmes.filter(pl.col("averageRating") > 7.5).select("tconst")

q3 = (
    principals
    .filter(pl.col("category").is_in(["actor", "actress"]))
    .join(filmes_75, on="tconst", how="inner")
    .group_by("nconst")
    .agg(pl.col("tconst").n_unique().alias("n_filmes"))
    .sort(["n_filmes", "nconst"], descending=[True, False])
    .head(3)
)
print(q3)
```

```
shape: (3, 2)

 nconst      n_filmes
 ---         ---
 str         u32

 nm0004660   199
```

```
  nm0595934   155
  nm3183374   124
```

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-10-14 18:33:44 -03"
```